ProveTok v3.0：完整数学工作流

方法 M1–M5 全推导、核验与流水线总结

2026 年 3 月 14 日

目录

1 执行摘要 **3**

2 统一符号表 **3**

3 流水线总览 **4**

4 M1：预算约束的 3D 证据 Token Bank（Stage 0–2） **4**

4.1 Stage 0：伪影风险评分 4

4.2 Sigmoid 软门控 5

4.3 Stage 1：冻结 3D 编码器 5

4.4 Stage 2：综合评分 5

4.5 自适应八叉树分裂算法 6

4.6 边界感知导出 6

5 M2：轻量跨模态路由器 **7**

5.1 线性投影与余弦路由 7

5.2 InfoNCE 训练损失：完整推导 7

5.2.1 第一步：Logit 与 Softmax 定义 7

5.2.2 第二步：单个正样本的损失项 8

5.2.3 第三步：梯度计算 8

5.2.4 第四步：互信息下界 8

5.2.5 第五步：多正样本平均 8

6 M3：逐句 Token 门控生成 **9**

6.1 Stage 3a：证据规划 9

6.2 Stage 3b：逐句路由 9

6.3 Stage 3c：Token 门控 LLM 生成 9

6.4 接口正确性：构造性引用 9

7 M4：规则校验器与一次性重路由（Stage 4–5） 9
7.1 Stage 4：规则化校验 9
7.2 Stage 5：句级软惩罚与重路由 10

8 M5：匹配计算量评估与统计协议 12
8.1 计算量匹配 12
8.2 注意力代价代理 12
8.2.1 朴素（无 KV-Cache）代理 12
8.2.2 KV-Cache 代理：逐步推导 12
8.3 病人级配对 Bootstrap 置信区间 13
8.4 Holm 步降多重比较校正 13

9 超参数总结 13

10 未决问题清单 14

11 方法–相关工作交叉引用 14

1 执行摘要

ProveTok v3.0 是一个六阶段流水线，用于生成带句级证据追溯的可验证 3D CT 放射报告。该流水线将 CT 体数据转化为预算约束的证据 *token bank*，通过轻量跨模态路由器将 token 子集路由到每句报告，在 token 门控接口下生成句子（构造性地保证引用正确性），应用规则校验器，并在统计稳健的评估协议下报告结果。

本文档提供每个阶段（方法 M1–M5）的**完整数学规范**，包括逐步推导、边界情形分析、单调性/有界性证明，以及统一的符号参考。

2 统一符号表

符号	描述
$V \in \mathbb{R}^{D\times H\times W}$	输入 CT 体数据
$F = \{f_i\}_{i=1}^{N}$	冻结 3D 编码器输出的特征图；$f_i \in \mathbb{R}^d$
$A_i \in [0,1]$	第 i 个空间单元的伪影风险分数
$g_i \in (0,1)$	由 A_i 导出的 sigmoid 软门控
H_i	第 i 个单元的不确定性（熵）
P_i	第 i 个单元的语义先验分数
$q(\cdot) \in [0,1]$	分位数归一化（按深度层、按病例）
$S_i \in [0,1)$	第 i 个单元的综合重要性分数
B	token 预算（默认 64）
k	每句 top-k 证据 token（默认 8）
$W_{\text{proj}} \in \mathbb{R}^{d_t\times d}$	可学习线性投影矩阵（路由器）
$v_i \in \mathbb{R}^{d_t}$	投影并归一化后的视觉 token 嵌入
$q_s \in \mathbb{R}^{d_t}$	句子主题 s 的文本查询嵌入
$r_i^{(s)}$	token i 对句子 s 的余弦路由分数
$\hat{r}_i^{(s)}$	加入空间先验后的路由分数
τ	InfoNCE 温度参数（默认 0.07）
$\mathcal{P}_s, \mathcal{N}_s$	句子 s 的正样本 / 负样本 token 集合
sev_i	规则违反的严重度权重
γ	对数平滑惩罚缩放因子（默认 2.0）
ϵ	解剖优先模式中语义 tiebreak 权重（默认 0.05）
θ_{ratio}	R1 侧别同侧 ratio 阈值（默认 0.6）
θ_{support}	R2 解剖支持率阈值（默认 0.8）

表 1: ProveTok v3.0 统一符号表。

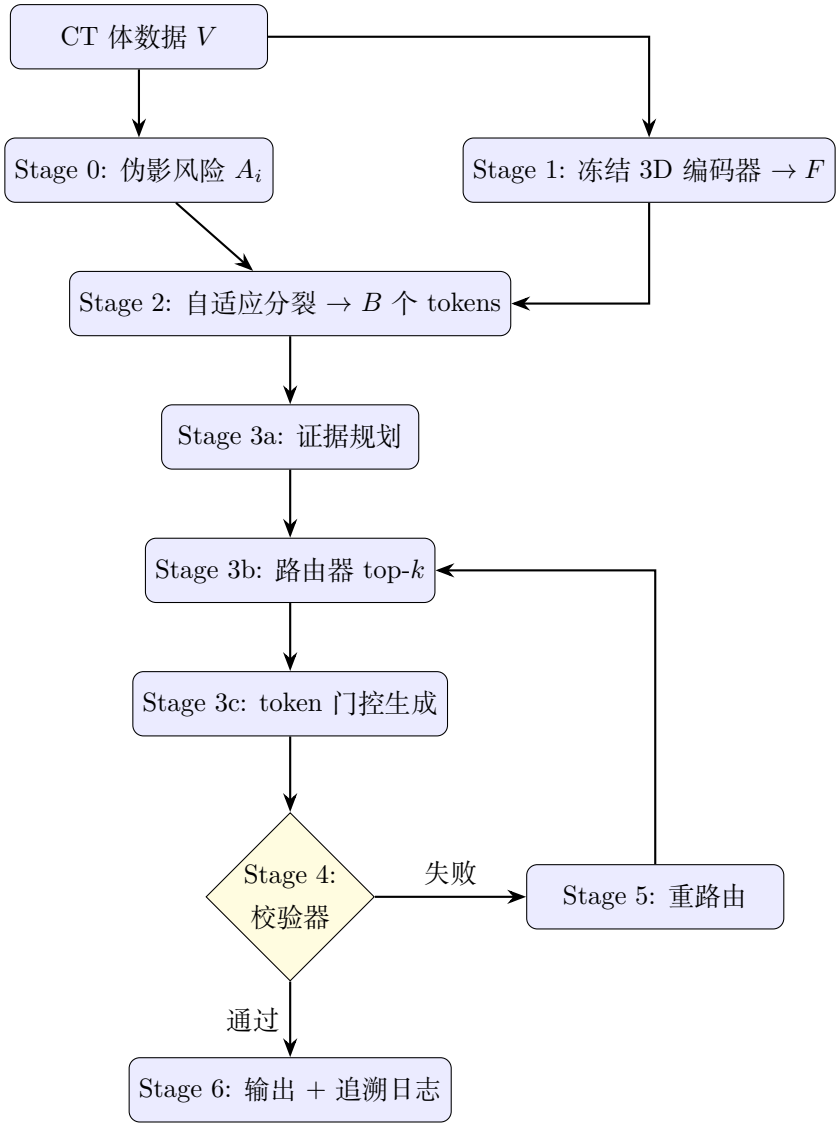

图 1: ProveTok v3.0 六阶段流水线。Stage 0–2 = **M1**（token bank），Stage 3b = **M2**（路由器），Stage 3c = **M3**（门控生成），Stage 4–5 = **M4**（校验 + 重路由），评估协议 = **M5**。

3 流水线总览

4 M1：预算约束的 3D 证据 Token Bank（Stage 0–2）

4.1 Stage 0：伪影风险评分

定义 4.1 (伪影风险分数)**.** 对每个空间单元 i:

$$A_i = \mathrm{clip}\left(w_{\mathrm{snr}} \cdot \mathrm{norm}\left(\frac{\sigma_i}{|\mu_i| + \epsilon} \right) + w_{\mathrm{st}} \cdot \mathrm{norm}(\mathrm{streak}_i) + w_{\mathrm{out}} \cdot \mathrm{norm}(\mathrm{outlier}_i),\ 0,\ 1 \right), \tag{1}$$

其中 μ_i, σ_i 为局部均值与标准差，streak_i 捕捉条纹状结构噪声，$\mathrm{outlier}_i$ 衡量体素级异常程度，$\mathrm{norm}(\cdot)$ 将各指标映射到 $[0, 1]$。权重满足 $w_{\mathrm{snr}} + w_{\mathrm{st}} + w_{\mathrm{out}} = 1$，默认 $(0.5, 0.3, 0.2)$。

设计动机。 逆信噪比项 $\sigma_i/(|\mu_i|+\epsilon)$ 在噪声主导时增大。条纹伪影（金属/射束硬化）与统计离群值提供互补检测通道。裁剪到 $[0,1]$ 保证 A_i 为有效的风险概率。

备注 4.1 (norm(·) 实现)**.** 代码中 norm(·) 采用 min-max 归一化：对同一批次的原始值 $\{x_i\}$，$\mathrm{norm}(x_i) = (x_i - x_{\min})/(x_{\max} - x_{\min})$。当 $x_{\max} = x_{\min}$ 时回退到常数 0.5。

4.2 Sigmoid 软门控

定义 4.2 (软门控)**.**

$$g_i = \sigma\big(-k_{\mathrm{gate}}(A_i - \tau_A)\big) = \frac{1}{1+\exp\big(k_{\mathrm{gate}}(A_i-\tau_A)\big)}, \tag{2}$$

其中 $k_{\mathrm{gate}} > 0$ 控制陡峭度（默认 15），$\tau_A \in (0,1)$ 为伪影阈值（默认 0.85）。

命题 4.1 (门控性质)**.** (i) **值域：** 对所有 $A_i \in [0,1]$，$g_i \in (0,1)$。

(ii) **单调性：** g_i 关于 A_i 严格递减。

(iii) **阈值行为：** $g_i(\tau_A) = 0.5$；$A_i \gg \tau_A \Rightarrow g_i \to 0$；$A_i \ll \tau_A \Rightarrow g_i \to 1$。

证明. (i) 由于 $\sigma(x) \in (0,1)$ 对所有 $x \in \mathbb{R}$ 成立，值域立即得证。

(ii) 对 A_i 求导：

$$\frac{\partial g_i}{\partial A_i} = \underbrace{\sigma(-k_{\mathrm{gate}}(A_i-\tau_A))}_{>0}\ \underbrace{(1-\sigma(-k_{\mathrm{gate}}(A_i-\tau_A)))}_{>0} \cdot \underbrace{(-k_{\mathrm{gate}})}_{<0} < 0. \tag{3}$$

因此 g_i 关于 A_i 严格递减。

(iii) 当 $A_i = \tau_A$ 时：$g_i = \sigma(0) = 0.5$。取默认值 $k_{\mathrm{gate}} = 15$, $\tau_A = 0.85$：

$$A_i = 1 \Rightarrow g_i \approx \sigma(-2.25) \approx 0.095, \quad A_i = 0 \Rightarrow g_i \approx \sigma(12.75) \approx 1.0.$$

□

4.3 Stage 1：冻结 3D 编码器

预训练的 3D 编码器（SwinUNETR，feature_size = 48，spatial_dims = 3）处理体数据 V，输出特征图 $F = \{f_i \in \mathbb{R}^d\}_{i=1}^N$。输入体积统一 resize 到 128^3。编码器权重**全程冻结**，无梯度回传。

4.4 Stage 2：综合评分

定义 4.3 (分位数归一化)**.** 对同一八叉树深度层、同一病例内的原始值 $\{x_i\}$：

$$q(x_i) = \frac{\mathrm{rank}(x_i)}{n}, \quad n = |\{x_j : \text{同一深度层}\}|. \tag{4}$$

在每轮处理中冻结（迭代分裂时不重算）。对离群值鲁棒，输出近似均匀分布。

定义 4.4 (综合重要性分数)**.**

$$S_i = g_i \cdot \big(\lambda_h\, q(H_i) + \lambda_p\, q(P_i)\big), \quad \lambda_h + \lambda_p = 1. \tag{5}$$

默认：$\lambda_h = 0.6$，$\lambda_p = 0.4$。

命题 4.2 (分数有界性)**.** 对所有合法输入，$S_i \in [0, 1)$。

证明. 由 $q(\cdot) \in [0, 1]$ 及 $\lambda_h + \lambda_p = 1$：

$$0 \le \lambda_h q(H_i) + \lambda_p q(P_i) \le 1.$$

由 $g_i \in (0, 1)$（命题 4.1）：

$$0 \le S_i = g_i \cdot (\lambda_h q(H_i) + \lambda_p q(P_i)) < 1.$$

下界在 $q(H_i) = q(P_i) = 0$ 时取到。上界严格小于 1，因为 $g_i < 1$。 □

4.5 自适应八叉树分裂算法

1. **初始化：**以整个体数据为单个根单元。
2. **选择候选：**在当前叶子中选 $i^* = \arg\max_i S_i$（需超过分裂阈值）。
3. **分裂：**将 i^* 细分为 8 个子单元；对每个子 j 计算 $f_j, A_j, g_j, H_j, P_j, S_j$。
4. **预算检查：**若叶子数 $\ge B$，执行 batched top-B + 空间 NMS 裁剪到恰好 B 个 token。
5. **终止：**无候选超过阈值，或预算耗尽。

该过程类似于 OctNet 的不平衡八叉树(叶节点存 pooled feature),但以 S_i(而非 occupancy)作为分裂准则，将空间分辨率集中在高重要性区域。

4.6 边界感知导出

定义 4.5 (边界上下文混合)**.** 对有邻居 $\mathcal{N}(i)$ 的导出 token i：

$$b_i = \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} f_j, \tag{6}$$

$$f_i^{\text{export}} = (1 - \beta)\, f_i + \beta\, b_i, \quad \beta \in [0, 1]. \tag{7}$$

默认 $\beta = 0.1$。边界框额外扩展 12.5%。

命题 4.3 (凸组合稳定性)**.**

$$\|f_i^{\text{export}}\| \le (1 - \beta)\|f_i\| + \beta\|b_i\| \le (1 - \beta)\|f_i\| + \frac{\beta}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|f_j\|. \tag{8}$$

若所有特征范数以 M 为界，则 $\|f_i^{\text{export}}\| \le M$。不会数值爆炸。

备注 4.2 (邻域为空的回退)**.** 当 $|\mathcal{N}(i)| = 0$（孤立叶节点）：令 $b_i = f_i$（等价 $\beta = 0$），得 $f_i^{\text{export}} = f_i$。

备注 4.3 (归一化交互)**.** 若 f_i 经 L_2 归一化，线性均值 b_i 可能改变方向与范数。建议：(a) 在归一化前混合，或 (b) 混合后重新归一化。需在论文中明确说明选择。

5 M2：轻量跨模态路由器

5.1 线性投影与余弦路由

定义 5.1 (视觉 token 投影)**.**

$$v_i = \frac{W_{\text{proj}} f_i}{\|W_{\text{proj}} f_i\|_2}, \quad v_i \in \mathbb{R}^{d_t}, \quad \|v_i\|_2 = 1. \tag{9}$$

仅 $W_{\text{proj}} \in \mathbb{R}^{d_t \times d}$ 可学习。

定义 5.2 (路由分数)**.** 给定 L_2 归一化的查询 q_s（$\|q_s\|_2 = 1$）：

$$r_i^{(s)} = \cos(q_s, v_i) = q_s^\top v_i \in [-1, 1]. \tag{10}$$

定义 5.3 (空间先验增强)**.** 当解剖关键词的边界框可用时：

$$\hat{r}_i^{(s)} = r_i^{(s)} + \lambda_{\text{spatial}} \cdot \text{IoU}(\text{bbox}_i, \text{bbox}_{\text{anatomy}}^{(s)}), \tag{11}$$

其中 $\text{IoU} \in [0, 1]$，$\lambda_{\text{spatial}} \geq 0$（默认 0.3）。因此 $\hat{r}_i^{(s)} \in [-1, 1 + \lambda_{\text{spatial}}]$。

按 $\hat{r}_i^{(s)}$ 取 top-k 的 token 构成句子 s 的证据集 E_s。

备注 5.1 (解剖优先路由模式)**.** 当 W_{proj} 尚未经过 InfoNCE 训练时（退化为单位矩阵），语义余弦分数 $r_i^{(s)}$ 不可靠。此时采用**解剖优先**模式：

$$\hat{r}_i^{(s)} = \text{IoU}(\text{bbox}_i,\ \text{bbox}_{\text{anatomy}}^{(s)}) + \epsilon \cdot r_i^{(s)}, \tag{12}$$

其中 $\epsilon \ll 1$（默认 0.05）使语义分数仅作为同 IoU token 间的 tiebreaker。该模式将空间 IoU 作为唯一有校准意义的信号，在 W_{proj} 训练完成后可切回标准模式 (11)。

5.2 InfoNCE 训练损失：完整推导

定义 5.4 (InfoNCE 损失)**.** 令 $\mathcal{C}_s = \mathcal{P}_s \cup \mathcal{N}_s$：

$$\mathcal{L}_s = -\frac{1}{|\mathcal{P}_s|} \sum_{i \in \mathcal{P}_s} \log \frac{\exp(\hat{r}_i^{(s)}/\tau)}{\sum_{j \in \mathcal{C}_s} \exp(\hat{r}_j^{(s)}/\tau)}. \tag{13}$$

默认 $\tau = 0.07$。

5.2.1 第一步：Logit 与 Softmax 定义

定义温度缩放 logit 与 softmax 分布：

$$z_j \triangleq \frac{\hat{r}_j^{(s)}}{\tau}, \qquad p_j \triangleq \frac{\exp(z_j)}{\sum_{u \in \mathcal{C}_s} \exp(z_u)}. \tag{14}$$

满足 $\sum_j p_j = 1$，$p_j > 0$。

5.2.2 第二步：单个正样本的损失项

对每个 $i \in \mathcal{P}_s$：

$$\ell_i = -\log p_i = -z_i + \log \sum_{u \in \mathcal{C}_s} \exp(z_u). \tag{15}$$

5.2.3 第三步：梯度计算

$$\frac{\partial \ell_i}{\partial z_j} = p_j - \mathbf{1}[j = i]. \tag{16}$$

推导过程：

$$\begin{aligned} \frac{\partial \ell_i}{\partial z_j} &= \frac{\partial}{\partial z_j}\Big(- z_i + \log \sum_u e^{z_u} \Big) \\ &= -\mathbf{1}[j = i] + \frac{e^{z_j}}{\sum_u e^{z_u}} = p_j - \mathbf{1}[j = i]. \end{aligned} \tag{17}$$

直觉解释：

- $j = i$（正样本）：梯度 $= p_i - 1 < 0 \Rightarrow$ 推动 z_i 增大（提升相似度）。
- $j \neq i$（负样本）：梯度 $= p_j > 0 \Rightarrow$ 推动 z_j 减小（降低相似度）。

与 MoCo/SimCLR/CLIP 的实现形式一致（logits/τ 送入交叉熵）。

5.2.4 第四步：互信息下界

根据 CPC（Oord et al., 2018）：

$$I(x; c) \geq \log |\mathcal{C}_s| - \mathcal{L}_s. \tag{18}$$

最优打分函数满足 $f^*(x, c) \propto p(x|c)/p(x)$（密度比）。训练 W_{proj} 即在冻结特征上学习该密度比的线性近似。

5.2.5 第五步：多正样本平均

当 $|\mathcal{P}_s| > 1$ 时：

$$\mathcal{L}_s = \frac{1}{|\mathcal{P}_s|} \sum_{i \in \mathcal{P}_s} \ell_i. \tag{19}$$

备注 5.2 ($|\mathcal{P}_s| = 0$ 的处理)**.** 当无正样本时损失未定义（除零）。策略：(1) 从批次中跳过该句；(2) 将最高 IoU 的 token 提升为正样本；(3) 仅用作其它句子的硬负样本。须记录选择并报告 $|\mathcal{P}_s|$ 分布。

备注 5.3 (温度与空间先验交互)**.** 空间先验在 logit 空间被 $1/\tau$ 放大。$\tau = 0.07$，$\lambda_{\text{spatial}} = 0.3$ 时最大 logit 增益 $= 0.3/0.07 \approx 4.3$，非常显著。强烈建议做 $(\lambda_{\text{spatial}}, \tau)$ 联合敏感性网格。

6 M3：逐句 Token 门控生成

6.1 Stage 3a：证据规划

规划器接收粗 token 子集（预算 $B_{\text{plan}} = \min(32, B/4)$），生成结构化计划：有序的句子主题列表，每句附带解剖关键词与目标深度层级。

6.2 Stage 3b：逐句路由

对每个计划的句子主题 s：

$$E_s = \text{top-k}_{i \in \{1,\ldots,B\}} \hat{r}_i^{(s)}, \quad |E_s| = k. \tag{20}$$

6.3 Stage 3c：Token 门控 LLM 生成

LLM **逐句调用**。对第 t 句：

- **可见输入（视觉前缀）**：仅 E_t 中 k 个 token 嵌入（按空间顺序拼接）+ 此前已生成句子的文本历史。
- **输出**：单个报告句子 y_t。

6.4 接口正确性：构造性引用

定义 6.1 (构造性引用)**.** 令 $E_t = \{e_{t,1}, \ldots, e_{t,k}\}$ 为路由到第 t 句的证据集，$\hat{E}_t$ 为输出中记录的引用集。由流水线构造：

$$\hat{E}_t \equiv E_t \quad \text{（精确集合相等）} \tag{21}$$

这保证了**溯源正确性**：每个引用都是模型可见的证据，每个可见 token 都被引用。无漏报，无多报。

备注 6.1 (接口正确性 $\neq$ 语义支持)**.** 方程 (21) 保证引用溯源正确，但不保证生成文本被引用证据语义支持。模型可能忽略视觉 token 而依赖语言先验（“虽引用正确但实质幻觉”）。语义支持须由 M4 校验器 + 外部 grounded 评估验证。

备注 6.2 (跨句一致性)**.** 多次独立 LLM 调用可能导致篇章漂移：同一病灶在不同句中描述不一致、侧别矛盾或冗余。文本历史前缀部分缓解此问题，但需显式跟踪跨句一致性指标。

7 M4：规则校验器与一次性重路由（Stage 4–5）

7.1 Stage 4：规则化校验

对每句及其引用 token 的边界框应用五类规则：

R1 — 侧别一致性。 若句子提及 “左”（“右”），则所有引用 token 的 bbox 中心须满足 $x_{\text{center}} > x_{\text{mid}}$（$< x_{\text{mid}}$），其中 x_{mid} 为标准化坐标系（LPS/RAS）下的中线。

R1 实现增强。 实际实现中，R1 引入三项改进以降低误报：

1. **Ratio 模式：** 将 cited tokens 按 token_side() 分为 same/opposite/cross 三类，仅当同侧比例 $\text{same_ratio} = |\text{same}|/(|\text{same}| + |\text{opp}|) < \theta_{\text{ratio}}$ 时触发 R1（默认 $\theta_{\text{ratio}} = 0.6$），取代原有的 all-or-nothing 判定。中线附近 token（cross）排除在分母之外。
2. **否定句豁免：** 否定句（如“未见左侧积液”）cite 的是背景区域 token，不要求侧别一致，跳过 R1。
3. **中线解剖词豁免：** mediastinum / trachea / carina / esophagus / aorta / spine / vertebra / sternum 等天然跨中线结构，cited tokens 必然覆盖双侧，跳过 R1。

R2 — 解剖区域一致性。 引用 token 的 bbox 须与句子暗示的解剖区域有非平凡 IoU（$> \tau_{\text{anatomy}}$）。

R2 实现增强。

1. **支持率模式：** 计算 cited tokens 中 IoU $> \tau_{\text{IoU}}$ 的比例 good_ratio，仅当 good_ratio $< \theta_{\text{support}}$（默认 0.8）时触发 R2，避免因单个离群 token 导致整句违规。
2. **大结构豁免：** bilateral / left lung / right lung 等覆盖大范围的解剖结构，其 bbox 与小 token bbox 的 IoU 天然极低，属于结构性误报，在 R2 中予以豁免（加入 `r2_skip_keywords`）。对于 mediastinum，通过将 τ_{IoU} 从 0.05 降至 0.04（经 mediastinum 阈值 sweep 实验确定的临界点）来消除误报，而非直接豁免。

R3 — 深度层级一致性。 引用 token 的八叉树深度须在所述发现类型的预期范围内。

R4 — 大小/范围合理性。 引用 token 的联合 bbox 须与所述发现的典型大小范围一致。

R5 — 否定处理。 若检测到否定（“未见…”），校验逻辑取反：引用 token 应不表现被否定的发现。

每条规则 r 输出：二值判定（通过/失败）及严重度 $\text{sev}_r \in [0, 1]$。默认严重度配置：$\text{sev}_{\text{R1}} = 1.0$、$\text{sev}_{\text{R2}} = 0.8$、$\text{sev}_{\text{R3}} = 0.7$、$\text{sev}_{\text{R4}} = 0.6$、$\text{sev}_{\text{R5}} = 1.0$。

备注 7.1 (当前实验中的规则启用状态)**.** 450/450 实验中：R4（大小/范围合理性）**已禁用**（阈值未校准）；R5 的回退词典**已禁用**（仅保留元数据级否定检测）。R1–R3 和 R6 正常启用。

R6 — 跨句一致性（增强规则）。 对同一解剖关键词下的所有句子进行跨句检查：

- **R6a — 侧别冲突：** 若同一解剖词在不同句子中声明相反侧别（一句说“左”，另一句说“右”），标记冲突（sev = 0.7）。
- **R6b — 存在/缺失冲突：** 若同一解剖词在一句中为阳性发现、在另一句中为否定发现，标记冲突（sev = 0.8）。

7.2 Stage 5：句级软惩罚与重路由

由于全局综合重要性分数 S_i 不直接决定单句的 Token 选取，惩罚应该尝试去直接施加于跨模态路由分数 $\hat{r}_i^{(s)}$ 以改变 top-k 采样结果。

定义 7.1 (句级严重度)**.** 对第 t 句（对应主题 s）涉及违规的 token i，汇聚其触发的规则严重度：

$$\mathrm{sev}_i^{(s)} = \max_{r \in \text{触发的规则}} \mathrm{sev}_r(i, s) \in [0, 1]. \tag{22}$$

（注：若 token i 未违规，则 $\mathrm{sev}_i^{(s)} = 0$）。

定义 7.2 (对数平滑惩罚)**.** 为避免硬性阈值截断导致的上下文断裂，对 token i 的路由分数施加基于严重度的对数平滑惩罚：

$$\hat{r}_i^{(s)\prime} = \hat{r}_i^{(s)} - \gamma \cdot \ln(1 + \mathrm{sev}_i^{(s)}), \tag{23}$$

其中 $\gamma > 0$ 为惩罚缩放因子（默认取 $\gamma = 2.0$）。

命题 7.1 (惩罚有界性与保序性)**.** (i) 已知 $\hat{r}_i^{(s)} \in [-1, 1 + \lambda_{\text{spatial}}]$ 且 $\mathrm{sev}_i^{(s)} \in [0, 1]$。新路由分数严格有界：

$$\hat{r}_i^{(s)\prime} \in [-1 - \gamma \ln 2, 1 + \lambda_{\text{spatial}}]. \tag{24}$$

若取默认值 $\gamma = 2.0$，最大惩罚量 $\Delta \approx 1.386$，足以抵消最大可能的空间先验增益（λ_{spatial}）并将其挤出 top-k。
(ii) 对于未违规的合规 token 集合（$\mathrm{sev}_i^{(s)} = 0$），其相对大小排序保持严格不变。

备注 7.2 (LLM 语义裁判（Stage 5 增强）)**.** 在对数平滑惩罚之前，可选地引入 LLM 语义裁判对 Stage 4 的每条违规做二次确认。LLM 接收违规句文本和规则描述，输出 $\{\text{confirmed} : \text{bool}, \text{severity} : [0, 1], \text{reasoning} : \text{str}\}$。仅对 LLM 确认的违规执行惩罚和重路由，未确认的违规视为误报并移除。该机制弥补了纯空间/几何规则缺乏语义理解能力的局限。当前实验使用 Llama-3.1-8B-Instruct（本地 bfloat16 推理），在 450/450 实验中过滤了约 54% 的 Stage 4 违规（从 974 条降至 449 条确认违规）。支持 Ollama / OpenAI / Anthropic / HuggingFace 四种后端。

重路由协议：

1. 用更新后的路由分数 $\{\hat{r}_i^{(s)\prime}\}$ 重新执行 top-k 采样，获取新证据集 E_s'。
2. 用新证据集 E_s' 重新生成失败的句子。
3. 对重新生成的句子再次执行 Stage 4 校验。
4. 若仍失败：降格表述（`despecify_text()`：移除空间定位词，包括侧别词 left/right、方位词 upper/lower/anterior/posterior、层级词 apical/basal/hilar 等），然后用降格后的主题重新生成。

仅一次重试，无递归重路由。

8 M5：匹配计算量评估与统计协议

8.1 计算量匹配

定义 8.1 (LLM Token 代价)**.** 对 J 次 LLM 调用：

$$C_{\mathrm{LLM}} = \sum_{j=1}^{J} (|p_j| + |g_j|), \tag{25}$$

其中 $|p_j|$ = 提示长度，$|g_j|$ = 生成长度。

备注 8.1 (C_{LLM} 实现简化)**.** 当前代码按**调用次数**统计 $C_{\mathrm{LLM}} = n_{\mathrm{gen}} + n_{\mathrm{judge}}$（包括重路由和降格表述产生的额外调用），尚未按公式逐调用记录 prompt/生成 token 数。完整的逐 token 统计需在 `stage3c_generator` 中记录 $|p_j|$ 和 $|g_j|$。

8.2 注意力代价代理

8.2.1 朴素（无 KV-Cache）代理

$$C_{\mathrm{attn}}^{\mathrm{naive}} = \sum_{j=1}^{J} (|p_j| + |g_j|)^2. \tag{26}$$

8.2.2 KV-Cache 代理：逐步推导

对第 j 次调用，提示长度 $p = |p_j|$，生成长度 $g = |g_j|$：

第一步：预填充。 对提示做完整自注意力：代价 $\propto p^2$。

第二步：增量生成。 在生成第 t 步（$t = 1, \ldots, g$），新 token 对长度为 $p + (t-1)$ 的上下文做注意力：

$$\text{第}t\text{ 步代价} = p + (t-1). \tag{27}$$

第三步：对生成步求和。

$$\sum_{t=1}^{g} (p + (t-1)) = gp + \sum_{t=0}^{g-1} t = gp + \frac{g(g-1)}{2}. \tag{28}$$

第四步：总代理。

$$\boxed{C_{\mathrm{attn}}^{\mathrm{cache}} = \sum_{j=1}^{J} \left(|p_j|^2 + |g_j| \cdot |p_j| + \frac{|g_j|(|g_j|-1)}{2} \right).} \tag{29}$$

备注 8.2 (替代约定)**.** 若每步 t 对长度 $p + t$ 的上下文做注意力（含当前 token）：

$$\sum_{t=1}^{g} (p + t) = gp + \frac{g(g+1)}{2}.$$

差异为 $O(g)$，作为代理可接受，但须明确约定。

8.3 病人级配对 Bootstrap 置信区间

定义 8.2 (配对 Bootstrap CI)**.** 给定 n 个病人的指标对 $\{(m_i^A, m_i^B)\}_{i=1}^n$，令 $\delta_i = m_i^A - m_i^B$：

1. 对 $b = 1, \ldots, R$（默认 $R = 5000$）：
   (a) 有放回抽 n 个下标。
   (b) 计算 $\bar{\delta}^{*(b)} = \frac{1}{n}\sum_{l=1}^n \delta_{i_l^*}$。
2. 对 R 个 bootstrap 均值排序。
3. $(1-\alpha)$ 分位数 CI：

$$\mathrm{CI}_{1-\alpha} = \left[\bar{\delta}^*_{(\lfloor R\alpha/2 \rfloor)},\ \bar{\delta}^*_{(\lceil R(1-\alpha/2) \rceil)}\right]. \tag{30}$$

为何按病人级采样？ 同一 CT 扫描内的句子相关（相同解剖、病理、图像质量）。按句级采样会低估方差，产生虚假窄 CI。病人级重采样保留组内相关性。

8.4 Holm 步降多重比较校正

定义 8.3 (Holm 校正)**.** 给定 m 个假设检验，按 p 值排序 $p_{(1)} \le \cdots \le p_{(m)}$：

1. 对 $k = 1, 2, \ldots, m$：比较 $p_{(k)}$ 与 $\alpha/(m-k+1)$。
2. 若 $p_{(k)} \le \alpha/(m-k+1)$ 且此前全部被拒绝，则拒绝 $H_{(k)}$。
3. 在第一个未被拒绝处停止。

控制族错误率（FWER）于 α 水平；一致优于 Bonferroni。

同时报告校正后与未校正 p 值，确保透明度。

备注 8.3 (M5 实现状态)**.** Bootstrap CI（$R = 5000$，按病人级抽样）和 Holm 步降校正均已在 `analyze_outputs.py` 中实现（`_bootstrap_ci()` 和 `_holm_correction()`），可在 450/450 实验结果上直接运行。

9 超参数总结

表 2: 默认值、文献范围与消融网格。

超参数	默认	文献范围	推荐	消融网格
Token 预算 B	64	Flamingo $\le$ 64; BLIP-2 = 32	128	$\{32, 64, 128\}$
每句 k	8	ContextCite top-k	8	$\{4, 8, 16\}$
规划预算 B_{plan}	$\min(32, B/4)$	BLIP-2 32 queries	32	$\{0, 16, 32\}$

超参数	默认	文献范围	推荐	消融网格
伪影阈值 τ_A	0.85	临床 SNR/CNR	0.85	$\{0.75, 0.85, 0.90\}$
门控陡峭度 k_{gate}	15	工程选择	15	$\{10, 15, 20\}$
权重 (w_e, w_v, w_b)	$(0.5, 0.3, 0.2)$	多信号融合	默认	± 0.1 扰动
评分融合 λ_h	0.6	无统一标准	0.6	$\{0.4, 0.6, 0.8\}$
边界混合 β	0.1	工程选择	0.1	$\{0, 0.05, 0.1, 0.2\}$
空间先验 λ_{spatial}	0.3	CT-GLIP grounded	0.3	$\{0, 0.1, 0.3, 0.5\}$
IoU 阈值 τ_{IoU}	0.1	弱监督标准	0.04	$\{0.03, 0.04, 0.05, 0.1\}$
InfoNCE 温度 τ	0.07	MoCo 0.07; SimCLR 0.1	0.07	$\{0.05, 0.07, 0.1, 0.2\}$
惩罚缩放 γ	2.0	工程选择	2.0	$\{1.0, 2.0, 3.0\}$
Anatomy tiebreak ϵ	0.05	工程选择	0.05	$\{0.01, 0.05, 0.1\}$
R1 ratio 阈值 θ_{ratio}	1.0	工程选择	0.6	$\{0.4, 0.6, 0.8, 1.0\}$
R2 支持率 θ_{support}	1.0	工程选择	0.8	$\{0.6, 0.8, 1.0\}$
Holm 校正	是	标准 FWER	是	固定
Bootstrap R	5000	1k–10k	5000	$\{1000, 5000, 10000\}$

10 未决问题清单

- ✓ **norm(·) 与 $q(\cdot)$ 的形式化定义：** 代码采用 min-max 归一化（norm）和分位数排名（q），按病例/深度层独立计算。Ties 按原始 enumerate 顺序分配排名。
- ✓ **3D NMS 规格：** 轴对齐 3D IoU，可配置 NMS 阈值（默认 1.0 即不做 NMS），全局执行。
- ✓ **侧别坐标系：** 预处理中统一为 LPS 朝向（`sitk.DICOMOrient(img, "LPS")`），x 轴：$0 =$ 患者右侧，$x_{\max} =$ 患者左侧。
- □ **$|\mathcal{P}_s| = 0$ 处理：** 当前实现抛出异常；尚未报告 $|\mathcal{P}_s|$ 分布。
- □ **$\lambda_{\text{spatial}} \times \tau$ 联合敏感性：** 提供网格消融，防止空间项在小 τ 下压倒语义路由。
- ✓ **sev_i 归一化：** 各规则严重度在配置中预设 $\in [0, 1]$；R1–R5 到逐 token 的映射通过 `severity_by_rule` 字典实现。
- ✓ **跨句一致性：** R6a（侧别冲突）和 R6b（存在/缺失冲突）已实现。
- □ **注意力代理约定：** 当前代码使用 $k \cdot B$ 简化代理，尚未按公式 (29) 逐调用计算。

11 方法–相关工作交叉引用

表 3: 方法 × 相关工作对照。

方法	**工作**	**对应关系**	**出处位置**
M1	OctNet	稀疏分层空间划分；叶节点 pooled 特征	摘要 + 引言
M1	TokenLearner	少量自适应 token 降低 $O(n^2)$ 注意力代价	Sec 3
M2	CLIP	余弦相似 + 温度缩放 softmax	Sec 3.1
M2	MoCo	$\tau = 0.07$ 默认；logits/τ+CE 实现	Sec 3.3
M2	CPC（InfoNCE）	分类交叉熵解释；密度比；MI 下界	Eq (4)–(5)
M2	CT-GLIP	3D grounded VLP；$\tau = 0.07$；局部对齐	方法部分
M3	RECLAIM	逐句引用；约束解码	Sec 4
M3	LongCite/CoF	逐句 top-l 检索 + 引用抽取	Sec 4.1
M3/4	ContextCite	top-k 归因优于全上下文验证	Fig 5
M3/4	CoVe	规划 → 核查 → 修订结构	摘要 +Sec 3
M4	侧别错误文献	关键词/正则的侧别筛查	综述
M5	Bootstrap 综述	重采样分位数 CI	方法部分
M5	Holm 校正	步降 FWER 控制	公式描述